

# **AVANCE PROYECTO INTELIGENCIA ARTIFICIAL**

**Store sales - Time series forecasting**

**Inteligencia artificial**

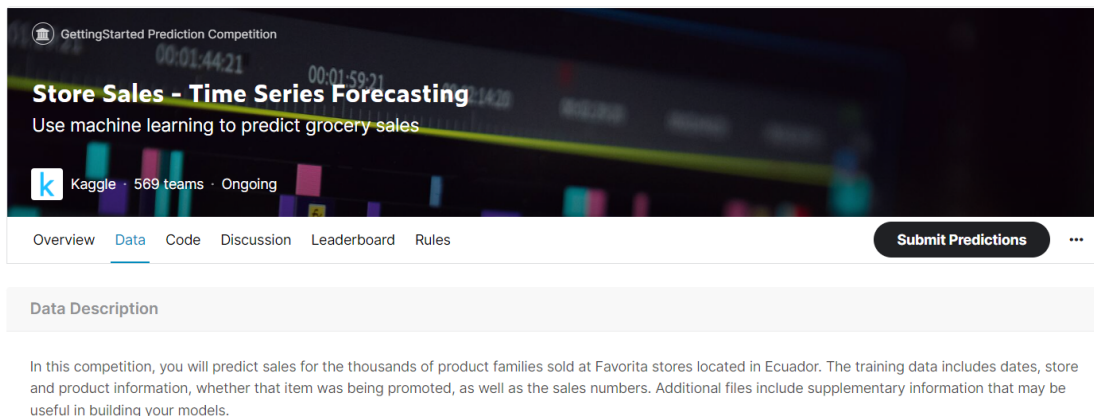
## **INTEGRANTES**

**Miguel Ángel Rivas Acevedo  
Santiago Lorduy Gil**

**UNIVERSIDAD DE ANTIOQUIA  
FACULTAD DE INGENIERÍA  
MEDELLÍN  
2022**

## Store sales - Time series forecasting

Se inicia buscando con mucho detenimiento y descargando uno a uno los datasets de diversas competencias en kaggle, se revisa y analiza el contenido, hasta que finalmente se encuentra un conjunto de datos que cumple con las características pedidas y una competencia agradable y que ve bastante prometedora e interesante para trabajar, esta se llama Store sales - Time series forecasting.



*Fig 1. Competencia elegida.*

En esta competencia contamos con un dataset de siete archivos, todos son .csv y se tiene uno para entrenar al algoritmo y otro para probarlo.

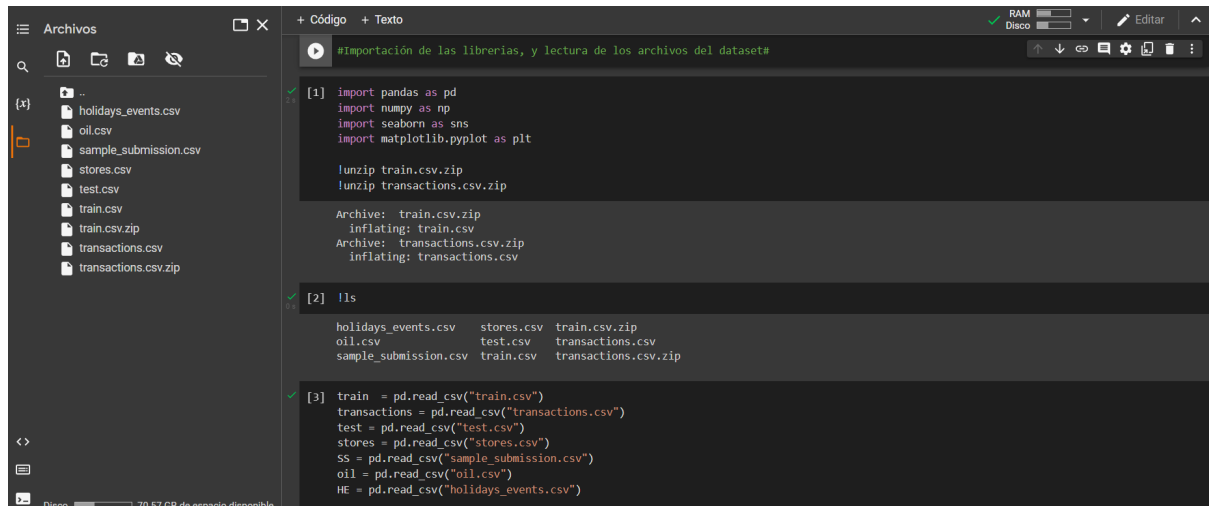
### Data Explorer

124.76 MB

- holidays\_events.csv
- oil.csv
- sample\_submission.csv
- stores.csv
- test.csv
- train.csv
- transactions.csv

*Fig 2. Dataset*

En el colab se importan todas las librerías necesarias y se suben todos los archivos, Se descomprimen los datos .zip de la competencia, posteriormente se realiza una lectura de los archivos usando la librería *pandas* y se imprime los datos de estos para ver su dimensión.



The screenshot shows a Jupyter Notebook environment. On the left, a file explorer pane displays a directory containing several CSV files and two ZIP archives: holidays\_events.csv, oil.csv, sample\_submission.csv, stores.csv, test.csv, train.csv, train.csv.zip, transactions.csv, and transactions.csv.zip. The main notebook area has a dark theme and shows three code cells. The first cell, titled '#Importación de las librerías, y lectura de los archivos del dataset', contains code to import pandas, numpy, seaborn, and matplotlib, and to unzip the train and transactions CSV archives. The second cell contains a terminal command 'ls' which lists the files in the current directory. The third cell contains code to load the CSV files into pandas DataFrames using pd.read\_csv().

```
#Importación de las librerías, y lectura de los archivos del dataset

[1] import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

!unzip train.csv.zip
!unzip transactions.csv.zip

Archive: train.csv.zip
  inflating: train.csv
Archive: transactions.csv.zip
  inflating: transactions.csv

[2] !ls

holidays_events.csv  stores.csv  train.csv.zip
oil.csv              test.csv   transactions.csv
sample_submission.csv train.csv  transactions.csv.zip

[3] train = pd.read_csv("train.csv")
transactions = pd.read_csv("transactions.csv")
test = pd.read_csv("test.csv")
stores = pd.read_csv("stores.csv")
ss = pd.read_csv("sample_submission.csv")
oil = pd.read_csv("oil.csv")
HE = pd.read_csv("holidays_events.csv")
```

Fig 3. Importación de los modulos y carga del dataset.

Después de observar el contenido de cada archivo, se utiliza la función `isnull.num` para ver qué columnas tienen valores NaN y así poder reemplazarlos por valores que puedan ser usados posteriormente con mayor eficiencia, para este caso se cambiaron por cero, debido a que tras hacer un análisis se concluyó que era la manera para que la ausencia no afectara el resultado. Continuando se realiza una concatenación de los archivos creando así un train y un test completos que facilitan la manipulación de datos y la facilidad para hacer gráficas con ellos e interpretarlos, todo esto para tener la mejor predicción posible.

